

# Desarrollo de Algoritmos de Recomendación Basados en la Geolocalización del Usuario: Un Estudio Comparativo

Dael Martínez Simón, Estudiante de la carrera Ingeniería en Software

[daelmartinezemail@micorreo.upp.edu.mx](mailto:daelmartinezemail@micorreo.upp.edu.mx)

Universidad Politécnica de Pachuca. Carr. Cdad. Sahagún-Pachuca Km. 20, Ex-Hacienda de Santa Bárbara, 43830 Zempoala, Hgo.

## RESUMEN

Este estudio aborda el desarrollo de un algoritmo de recomendación que utiliza la geolocalización del usuario para mejorar la precisión y relevancia de las recomendaciones de productos y servicios. Se realiza un análisis comparativo de tres investigaciones clave que combinan técnicas de filtro colaborativo y filtro basado en contenido, integrando la localización GPS del usuario. La metodología empleada incluye la recopilación de datos de los sitios web TripAdvisor y Foursquare, así como la aplicación de un clasificador bayesiano con técnicas de procesamiento de lenguaje natural (PLN). Los resultados experimentales demuestran que el enfoque híbrido propuesto mejora significativamente las métricas de precisión y recall en comparación con los métodos tradicionales. Las conclusiones indican que la integración de la geolocalización en los algoritmos de recomendación no solo incrementa la exactitud de las recomendaciones, sino que también enriquece la experiencia del usuario. Además, se proponen nuevas direcciones para investigaciones futuras, enfocadas en la optimización y adaptación del algoritmo a diferentes contextos y tipos de usuarios.

**Palabras clave:** Algoritmo de recomendación, geolocalización del usuario, filtro colaborativo, filtro basado en contenido, procesamiento de lenguaje natural.

## Development of Recommendation Algorithms Based on User Geolocation: A Comparative Study

### ABSTRACT

This study addresses the development of a recommendation algorithm that uses user geolocation to enhance the accuracy and relevance of product and service recommendations. A comparative analysis of three key research studies is conducted, combining collaborative filtering and content-based filtering techniques with the integration of the user's GPS location. The methodology includes data collection from TripAdvisor and Foursquare, and the application of a Bayesian classifier with natural language processing (NLP) techniques. Experimental results show that the proposed hybrid approach significantly improves precision and recall metrics compared to traditional methods. The conclusions indicate that integrating geolocation into recommendation algorithms not only increases recommendation accuracy but also enriches the user experience. Furthermore, new directions for future research are proposed, focusing on the optimization and adaptation of the algorithm to different contexts and user types.

**Keywords:** *Recommendation algorithm, user geolocation, collaborative filtering, content-based filtering, natural language processing.*

## **1. INTRODUCCIÓN**

En la era de la información, los sistemas de recomendación son herramientas esenciales para ayudar a los usuarios a encontrar productos y servicios que se ajusten a sus preferencias. La incorporación de la geolocalización en estos sistemas mejora significativamente la precisión y relevancia de las recomendaciones, proporcionando una experiencia más personalizada.

El objetivo de este artículo es desarrollar un algoritmo de recomendación basado en la geolocalización del usuario. Para ello, se realiza un análisis comparativo de tres investigaciones clave:

**"Análisis, diseño y desarrollo de un sistema de recomendación basado en datos restauranteros de TripAdvisor y Foursquare"** por Saúl Pérez et al., que propone un algoritmo híbrido combinando filtros colaborativos y basados en contenido, con un clasificador bayesiano y técnicas de procesamiento de lenguaje natural, integrando la localización GPS del usuario.

**"Diseño y desarrollo de una aplicación PWA para un E-Commerce que permita la recomendación de productos basado en algoritmos inteligentes"** por Ángel Mesias Jadan Corte, que describe la implementación práctica del algoritmo KNN utilizando datos de redes sociales y una arquitectura de microservicios.

**"Sistema de recomendación de artículos de línea blanca basado en el algoritmo KNN"** por Guevara-Fernandez, Alexander y Coral-Ygnacio, Marco A., que se centra en la implementación de un sistema de recomendación utilizando el algoritmo K-Nearest Neighbors (KNN), integrando la similitud entre productos y la localización geográfica para mejorar la relevancia de las recomendaciones.

Estos estudios proporcionan una base sólida para la creación de un algoritmo híbrido que combina las mejores prácticas identificadas y la integración de la geolocalización. La metodología incluye la recopilación y análisis de datos, y la implementación y evaluación del algoritmo propuesto.

## **2. REVISION DE LA LITERATURA**

**Artículo 1: "Análisis, diseño y desarrollo de un sistema de recomendación basado en datos restauranteros de TripAdvisor y Foursquare"**

**Autores:** Saúl Pérez, Mary Carmen Cuecuecha, José Federico Ramírez, José Crispín Hernández

Pérez, S., Cuecuecha, M. C., Ramírez, J. F., & Hernández, J. C. (2018). Nos sugiere un estudio que se centra en mejorar la precisión y relevancia de las recomendaciones mediante la combinación de varias técnicas de filtrado y el uso de la geolocalización del usuario. Los sistemas de recomendación son esenciales en el contexto actual debido a la sobrecarga de información en internet, y su aplicación en la industria restaurantera puede mejorar significativamente la experiencia del usuario.

## Metodología y Técnicas Utilizadas

### Recopilación de Datos

**TripAdvisor y Foursquare:** Los autores recopilaron datos de reseñas, calificaciones y ubicaciones geográficas de restaurantes utilizando las APIs de TripAdvisor y Foursquare. Esta recopilación proporciona un conjunto de datos diverso y rico en información, incluyendo opiniones de usuarios y la ubicación física de los restaurantes.

### Filtro Colaborativo

- **Similitud Coseno:** El método de filtro colaborativo basado en ítems se implementa utilizando la similitud coseno para calcular las similitudes entre restaurantes. Esta técnica es efectiva para identificar ítems similares basados en las calificaciones proporcionadas por los usuarios.
- **Matriz Usuario-Ítem:** Los datos recopilados se estructuran en una matriz de usuario-ítem, donde las filas representan a los usuarios y las columnas a los restaurantes. Las entradas en esta matriz corresponden a las calificaciones que los usuarios han dado a los restaurantes, permitiendo así identificar patrones de preferencia.

### Filtro Basado en Contenido

- **Procesamiento de Lenguaje Natural (PLN):** Para analizar las descripciones y comentarios de los usuarios, se emplean técnicas de PLN como la tokenización, eliminación de palabras vacías y lematización. Estas técnicas permiten extraer características relevantes del texto.
- **Clasificador Bayesiano:** Un clasificador bayesiano se utiliza para categorizar los comentarios de los usuarios según su polaridad (positiva, negativa o neutral). Esta clasificación ayuda a comprender mejor las opiniones de los usuarios y a mejorar la precisión de las recomendaciones.

### Integración de Geolocalización

- **Datos GPS:** La ubicación GPS del usuario se utiliza como un filtro adicional para mejorar la relevancia de las recomendaciones. Al considerar la proximidad geográfica, el sistema puede recomendar restaurantes que estén dentro de un radio razonable desde la ubicación actual del usuario.
- **Filtro Geográfico:** Se implementa un filtro geográfico que calcula la distancia entre la ubicación del usuario y los restaurantes, asegurando que las recomendaciones sean geográficamente accesibles.

### Resultados y Evaluación

#### Métricas de Precisión y Recall

- **Resultados Experimentales:** Los resultados experimentales indican que el sistema híbrido propuesto mejora significativamente las métricas de precisión y recall en comparación con los métodos tradicionales de recomendación. La incorporación de la geolocalización resultó en recomendaciones más relevantes y personalizadas.

- **Comparación con Métodos Tradicionales:** El artículo compara el rendimiento del sistema híbrido con los enfoques de filtro colaborativo y basado en contenido de manera independiente. Los hallazgos demuestran que la combinación de estos métodos, junto con la integración de la geolocalización, ofrece una mejora sustancial en la calidad de las recomendaciones.

### **Desafíos y Limitaciones**

#### **Limitaciones del Sistema Híbrido:**

Aunque el sistema híbrido muestra mejoras significativas, enfrenta desafíos en términos de escalabilidad y manejo de grandes volúmenes de datos, especialmente cuando se utilizan técnicas intensivas en recursos como el procesamiento de lenguaje natural y la clasificación bayesiana.

#### **Dependencia de Datos Externos:**

La calidad y precisión de las recomendaciones dependen en gran medida de la precisión y relevancia de los datos obtenidos de TripAdvisor y Foursquare. Cualquier cambio en las APIs o en la disponibilidad de datos puede afectar el rendimiento del sistema.

### **Propuestas de Mejora**

#### **Exploración de Algoritmos Alternativos:**

- Considerar la implementación de algoritmos más escalables y eficientes como SVD (Singular Value Decomposition) o modelos de deep learning que puedan manejar grandes volúmenes de datos de manera más eficiente.

#### **Ampliación de Fuentes de Datos:**

- Integrar datos adicionales de otras plataformas de reseñas y redes sociales para enriquecer el conjunto de datos y mejorar la precisión de las recomendaciones.

#### **Optimización del Procesamiento de Lenguaje Natural:**

- Utilizar técnicas avanzadas de PLN y modelos preentrenados como BERT o GPT-3 para mejorar la comprensión y clasificación de los comentarios de los usuarios.

### **Impacto y Aplicaciones Prácticas**

#### **Relevancia en la Industria Restaurantera:**

- Los sistemas de recomendación basados en datos restauranteros pueden transformar la experiencia del usuario, ayudándolos a descubrir restaurantes que se ajusten mejor a sus gustos y necesidades. Esto no solo mejora la satisfacción del cliente, sino que también puede aumentar la lealtad y las tasas de retorno de los clientes.

#### **Aplicaciones en Otros Sectores:**

- La metodología híbrida y la integración de geolocalización pueden ser aplicadas a otros sectores como turismo, retail y entretenimiento, donde la personalización de las recomendaciones y la relevancia geográfica son igualmente importantes.

## **Conclusiones del Artículo**

El estudio de Saúl Pérez et al. proporciona una evidencia sólida de que la integración de múltiples técnicas de recomendación y el uso de datos de geolocalización pueden mejorar significativamente la precisión y relevancia de los sistemas de recomendación. La metodología híbrida y la aplicación de técnicas avanzadas de PLN y geolocalización representan un enfoque robusto y efectivo para la personalización de recomendaciones en el contexto de restaurantes. Estos hallazgos son altamente relevantes para la investigación actual en algoritmos de recomendación de productos basados en la ubicación del usuario, sugiriendo que la combinación de técnicas y la consideración de factores geográficos son esenciales para desarrollar sistemas de recomendación más precisos y útiles.

## **Análisis del Artículo: "Diseño y desarrollo de una aplicación PWA para un E-Commerce que permite la recomendación de productos basado en algoritmos inteligentes"**

**Autores:** Ángel Mesias Jadan Corte

Jadan Corte, Á. M. (2024). Presenta un enfoque innovador para mejorar la experiencia del usuario en plataformas de e-commerce mediante la implementación de sistemas de recomendación. Los sistemas de recomendación son cruciales en el e-commerce moderno, ya que personalizan la experiencia del usuario, aumentando las tasas de conversión y la satisfacción del cliente. Este análisis profundiza en los métodos y algoritmos utilizados en el estudio, proporcionando una base para el desarrollo de sistemas de recomendación más avanzados.

### **Metodología y Técnicas Utilizadas**

#### **Recopilación de Datos:**

Facebook: Los datos se recopilan a partir de publicaciones de productos en Facebook, incluyendo comentarios y reacciones de los usuarios. Esta recopilación proporciona un conjunto de datos diverso y rico en información, esencial para entrenar un sistema de recomendación efectivo.

#### **Algoritmo K-Nearest Neighbors (KNN):**

- **Similitud Euclídea:** El algoritmo KNN se implementa utilizando la distancia euclídea para calcular similitudes entre productos. Esta técnica es efectiva para identificar productos similares basados en las interacciones de los usuarios.
- **Matriz Usuario-Producto:** La estructura de datos en una matriz usuario-producto permite identificar patrones de preferencia y proporcionar recomendaciones personalizadas.

#### **Procesamiento de Lenguaje Natural (PLN):**

- Tokenización, Eliminación de Palabras Vacías y Lematización: Estas técnicas de PLN son cruciales para analizar los comentarios de los usuarios y extraer características relevantes del texto, mejorando la calidad de los datos utilizados para las recomendaciones.

- Clasificador Bayesiano: Utilizado para categorizar los comentarios según su polaridad (positiva, negativa o neutral), este clasificador ayuda a comprender mejor las opiniones de los usuarios y a mejorar la precisión de las recomendaciones.

## Resultados y Evaluación

### **Métricas de Precisión y Recall:**

Los resultados experimentales indican que el sistema basado en KNN y técnicas de PLN mejora significativamente las métricas de precisión y recall en comparación con los métodos tradicionales.

### **Comparación con Métodos Tradicionales:**

El artículo demuestra que la integración de comentarios de redes sociales y técnicas de PLN ofrece una mejora sustancial en la calidad de las recomendaciones, superando los enfoques tradicionales de filtrado colaborativo y basado en contenido.

## Desafíos y Limitaciones

### **Limitaciones del Algoritmo KNN:**

KNN, aunque efectivo para conjuntos de datos pequeños a medianos, enfrenta desafíos de escalabilidad cuando se aplica a grandes volúmenes de datos debido a su alto costo computacional y requerimientos de almacenamiento.

### **Propuestas de Mejora:**

- Considerar la implementación de algoritmos más escalables como SVD (Singular Value Decomposition) o modelos basados en deep learning que puedan manejar grandes volúmenes de datos de manera más eficiente.
- Integrar datos adicionales, como transacciones de compra y datos de geolocalización, para enriquecer el sistema de recomendación.

### **Impacto y Aplicaciones Prácticas**

Los sistemas de recomendación basados en algoritmos inteligentes, como el desarrollado en este estudio, tienen un impacto significativo en el e-commerce. Al personalizar la experiencia del usuario y ofrecer recomendaciones más precisas, estos sistemas pueden aumentar las tasas de conversión y mejorar la satisfacción del cliente. Además, la metodología presentada puede aplicarse a otros contextos, como la recomendación de servicios locales y contenido digital.

### **Conclusiones del Artículo**

El estudio de Ángel Mesias Jadan Corte proporciona una base sólida para la implementación de sistemas de recomendación en e-commerce. La integración de técnicas de procesamiento de lenguaje natural y el uso de datos de redes sociales mejoran significativamente la precisión y relevancia de las recomendaciones. Estos hallazgos son altamente relevantes para la investigación actual en algoritmos de recomendación, sugiriendo que la combinación de técnicas de PLN y la consideración de factores sociales son esenciales para desarrollar sistemas de recomendación más precisos y útiles.

## Análisis del Artículo: "Sistema de recomendación de artículos de línea blanca basado en el algoritmo KNN"

**Autores:** Alexander Guevara-Fernández, Marco A. Coral-Ignacio

El artículo de Fernandez, A. G., & Ygnacio, M. A. C. (2023). Presenta un estudio que busca mejorar el proceso de marketing digital en el comercio electrónico, ahorrando tiempo a los clientes en su búsqueda y decisión de compra mediante recomendaciones precisas basadas en sus preferencias.

### Metodología y Técnicas Utilizadas

#### Recopilación de Datos

- **Identificación de Variables:** Los autores trabajaron con más de 100 productos diferentes, identificados mediante variables como color, marca, modelo y precio. Estas variables son cruciales para calcular las distancias entre los productos y las preferencias de los usuarios.

#### Algoritmo K-Nearest Neighbors (KNN)

**Descripción del Algoritmo:** El algoritmo KNN es un método de aprendizaje supervisado utilizado para clasificación y regresión. En este contexto, se utiliza para recomendar productos similares basados en las preferencias del usuario.

#### Proceso de Cálculo:

1. **Ingreso de Preferencias:** Se ingresan las preferencias del usuario, que incluyen hasta doce variables.
2. **Cargado de Datos:** Los datos de los productos se cargan desde la base de datos.
3. **Cálculo de Distancias:** Se calcula la distancia entre cada producto en la base de datos y las preferencias del usuario utilizando la distancia euclídea.
4. **Almacenamiento y Ordenamiento:** Las distancias se almacenan y ordenan.
5. **Generación de Recomendaciones:** Se recomiendan los "N" productos más cercanos a las preferencias del usuario.

**Fórmula de la Distancia Euclídea:** La distancia euclídea entre dos puntos  $x$  e  $y$  en un espacio n-dimensional se calcula como:

$$\text{dist}(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Imagen 1 Fórmula de distancia Euclídea

Donde:

- $x$  y  $y$  son vectores de las características de los productos.
- $x_i$  y  $y_i$  son las i-ésimas características de los vectores.

#### Implementación del Algoritmo:

- **Lectura de Variables:** Se ingresan las variables de las preferencias del usuario:  $V = \{V_1, V_2, \dots, V_{12}\}$
- **Cargado de Datos:** Se cargan los datos de los productos desde la base de datos en un arreglo:  $\text{ArrayBD\_LB} = \{P_1, P_2, \dots, P_n\}$
- **Cálculo de la Distancia Euclíadiana:** Para cada producto en la base de datos, se calcula la distancia euclíadiana con respecto a las preferencias del usuario:

$$\text{dist}(V, P_j) = \sqrt{\sum_{i=1}^{12} (V_i - P_{j,i})^2}$$

Imagen 2 Calculo de la distancia Euclíadiana

- **Almacenamiento y Ordenamiento:** Las distancias calculadas se almacenan y se ordenan de menor a mayor:  $\text{ArrayResult} = \{(\text{dist1}, P_1), (\text{dist2}, P_2), \dots, (\text{distn}, P_n)\}$ .
- **Generación de Recomendaciones:** Se seleccionan los "N" productos más cercanos a las preferencias del usuario:

$\text{Recomendaciones} = \{\text{ArrayResult}[1], \text{ArrayResult}[2], \dots, \text{ArrayResult}[N]\}$

Imagen 3 Formula de recomendaciones

## Evaluación y Resultados

### Métricas de Precisión y Recall

- **Resultados Experimentales:** Los resultados muestran que el sistema es eficiente en la recomendación de productos, logrando recomendaciones precisas y relevantes basadas en las preferencias de los clientes.
- **Eficiencia del Algoritmo:** El uso de KNN con distancia euclíadiana demostró ser efectivo para generar recomendaciones que alinean con los gustos y necesidades de los usuarios.

### Desafíos y Limitaciones

#### Limitaciones del Algoritmo KNN:

- **Escalabilidad:** KNN puede enfrentar problemas de escalabilidad cuando se trabaja con grandes volúmenes de datos debido a su alto costo computacional.

#### Dependencia de Datos de Entrada:

- **Calidad de Datos:** La precisión de las recomendaciones depende en gran medida de la calidad y relevancia de los datos de entrada. Variables mal definidas o datos incompletos pueden afectar la efectividad del sistema.

### Propuestas de Mejora

#### Exploración de Algoritmos Alternativos:

- **Algoritmos Escalables:** Considerar el uso de algoritmos más escalables como la factorización de matrices (SVD) o modelos de deep learning para mejorar la eficiencia y manejar grandes volúmenes de datos.

#### **Ampliación de Fuentes de Datos:**

- **Integración de Datos Adicionales:** Incorporar datos adicionales de otras fuentes, como redes sociales y plataformas de reseñas, para enriquecer el conjunto de datos y mejorar la precisión de las recomendaciones.

#### **Optimización del Procesamiento de Datos:**

- **Técnicas Avanzadas de PLN:** Utilizar técnicas avanzadas de procesamiento de lenguaje natural (PLN) para analizar mejor los comentarios y reseñas de los usuarios, mejorando así la calidad de los datos utilizados para las recomendaciones.

### **Impacto y Aplicaciones Prácticas**

#### **Relevancia en el Comercio Electrónico:**

- **Mejora de la Experiencia del Usuario:** Los sistemas de recomendación mejoran la experiencia del usuario al proporcionar sugerencias personalizadas, lo que puede aumentar la satisfacción del cliente y las tasas de conversión.

#### **Aplicaciones en Diversos Sectores:**

- **Versatilidad del Algoritmo:** Aunque este estudio se centra en productos de línea blanca, la metodología puede aplicarse a otros sectores, como la moda, los libros y los servicios, donde la personalización de recomendaciones es igualmente importante.

### **Conclusiones del Artículo**

El estudio de Alexander Guevara-Fernández y Marco A. Coral-Ignacio demuestra que el algoritmo KNN es una herramienta eficaz para desarrollar sistemas de recomendación en el comercio electrónico. La precisión y relevancia de las recomendaciones pueden mejorarse significativamente mediante el uso de la distancia euclídea y un conjunto bien definido de variables. Sin embargo, la escalabilidad y la calidad de los datos siguen siendo desafíos importantes. Futuras investigaciones podrían centrarse en la integración de técnicas más avanzadas y escalables, así como en la ampliación de las fuentes de datos para enriquecer el sistema de recomendación.

## **3. METODOLOGIA**

### **1. Recopilación de Datos**

La recopilación de datos es un paso crucial en el desarrollo de cualquier algoritmo de recomendación. Para esta investigación, se han recopilado datos de múltiples fuentes confiables para asegurar una base de datos diversa y completa. Los datos se obtuvieron de las siguientes fuentes:

- **TripAdvisor y Foursquare:** Estas plataformas proporcionaron datos de reseñas y calificaciones de usuarios sobre diversos productos y servicios. Se accedió a la API de ambas plataformas para extraer la información necesaria.
- **Redes Sociales:** Los datos adicionales se obtuvieron de comentarios y publicaciones en redes sociales como Facebook y Twitter, utilizando técnicas de web scraping y la API de GraphQL para Facebook.
- **Bases de Datos de E-Commerce:** Se integraron datos de inventarios y características de productos de tiendas en línea.

Las variables recolectadas incluyen:

- **Calificaciones de Usuarios:** Información sobre las calificaciones numéricas otorgadas por los usuarios.
- **Comentarios de Usuarios:** Opiniones textuales detalladas proporcionadas por los usuarios.
- **Ubicaciones GPS:** Datos de ubicación que permiten asociar la geolocalización del usuario y de los productos o servicios recomendados.
- **Características de los Productos:** Información detallada de los productos, incluyendo marca, modelo, precio, color, tipo de consumo energético, función, tipo de producto, tipo de material, garantía, cantidad de likes, cantidad de vistas y capacidad.

## 2. Algoritmo de Recomendación Propuesto

El algoritmo de recomendación propuesto es un sistema híbrido que integra técnicas de filtro colaborativo, filtro basado en contenido y geolocalización. Este enfoque aprovecha las ventajas de cada técnica para mejorar la precisión y relevancia de las recomendaciones.

### Descripción del Algoritmo:

- **Filtro Colaborativo:** Utiliza técnicas de filtrado basado en usuarios y en ítems. El enfoque basado en usuarios identifica similitudes entre usuarios para recomendar ítems que usuarios similares han calificado positivamente. El enfoque basado en ítems encuentra similitudes entre ítems para recomendar productos similares a los que el usuario ya ha calificado positivamente.
- **Filtro Basado en Contenido:** Analiza las características textuales de los productos y los comentarios de los usuarios. Se utilizan técnicas de procesamiento de lenguaje natural (PLN) para extraer características y clasificar los comentarios en términos de polaridad (positiva, negativa o neutral).
- **Geolocalización:** Integra datos de ubicación GPS para asegurar que las recomendaciones sean relevantes geográficamente.

### Procesamiento de Datos:

Para el procesamiento de datos, se emplearon varias técnicas avanzadas:

- **Tokenización y Lematización:** Estas técnicas de PLN se utilizaron para preprocesar los comentarios de los usuarios. La tokenización descompone el texto en palabras individuales (tokens), y la lematización reduce las palabras a su forma base o lema.
- **Vectorización de Texto:** Se utilizó la técnica de TF-IDF (Term Frequency-Inverse Document Frequency) para convertir el texto en vectores numéricos que el algoritmo pueda procesar.
- **Clasificación de Sentimientos:** Se aplicó un clasificador bayesiano para analizar y categorizar los comentarios de los usuarios en términos de sentimientos.

### **Implementación del Algoritmo:**

La implementación del algoritmo se realizó en varias etapas:

#### **1. Instalación de Bibliotecas Necesarias**

```
# !pip install pandas scikit-learn numpy tensorflow gensim
```

#### **2. Importación de Bibliotecas:**

```
import pandas as pd
import numpy as np
from sklearn.metrics.pairwise import cosine_similarity
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.preprocessing import StandardScaler
from sklearn.naive_bayes import MultinomialNB
from sklearn.cluster import KMeans
from sklearn.decomposition import LatentDirichletAllocation as LDA
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Embedding, Flatten
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.preprocessing.sequence import pad_sequences
```

#### **3. Cargar Datos:** Se crean dataframes para almacenar las calificaciones de los usuarios, comentarios sobre los productos, ubicaciones de los usuarios y detalles de los productos.

```
# Datos de calificaciones
ratings = pd.DataFrame({
    'user_id': [1, 2, 3, 4, 5],
    'item_id': [101, 102, 103, 104, 105],
    'rating': [5, 4, 3, 5, 4],
    'timestamp': [1622476800, 1622563200, 1622649600, 1622736000, 1622822400] # Timestamps
})
```

```

# Datos de comentarios
comments = pd.DataFrame({
    'item_id': [101, 102, 103, 104, 105],
    'comment': [
        "Excelente iPhone 12, muy recomendable",
        "Samsung Galaxy S21, buena compra",
        "Google Pixel 5, buena relación calidad-precio",
        "Refrigerador LG, muy eficiente",
        "Refrigerador Samsung, satisface mis necesidades"
    ]
})

# Datos de ubicaciones (GPS)
locations = pd.DataFrame({
    'user_id': [1, 2, 3, 4, 5],
    'latitude': [34.0522, 36.1699, 40.7128, 41.8781, 34.0622], # Los Ángeles, Las Vegas, Nueva York, Chicago, Cerca de Los Ángeles
    'longitude': [-118.2437, -115.1398, -74.0060, -87.6298, -118.2537]
})

# Datos de productos
products = pd.DataFrame({
    'item_id': [101, 102, 103, 104, 105],
    'name': ["iPhone 12", "Samsung Galaxy S21", "Google Pixel 5", "Refrigerador LG", "Refrigerador Samsung"],
    'latitude': [34.0525, 36.1600, 40.7100, 41.8800, 34.0630], # Coordenadas ajustadas para evitar coincidencias exactas
    'longitude': [-118.2450, -115.1500, -74.0070, -87.6300, -118.2500]
})

```

#### 4. Procesamiento de datos:

- **Filtro Basado en Contenido:** Se vectorizan los comentarios usando TF-IDF y se calcula la similitud coseno entre los productos.

```

tfidf = TfidfVectorizer(stop_words='english')
tfidf_matrix = tfidf.fit_transform(comments['comment'])

# Similitud coseno entre productos basados en comentarios
cosine_sim = cosine_similarity(tfidf_matrix, tfidf_matrix)

```

5. **Cálculo de Similitud:** Se utilizó la similitud coseno para medir la similitud entre ítems basándose en las calificaciones de los usuarios. También se aplicó un clasificador

bayesiano para analizar y categorizar los comentarios de los usuarios. La fórmula utilizada es:

$$\text{sim}(i, j) = \frac{\sum_{u \in U} r_{u,i} \cdot r_{u,j}}{\sqrt{\sum_{u \in U} r_{u,i}^2} \cdot \sqrt{\sum_{u \in U} r_{u,j}^2}}$$

Imagen 4 Formula de similitud

```
# Crear matriz de calificaciones
rating_matrix = ratings.pivot_table(index='user_id', columns='item_id',
values='rating').fillna(0)

# Similitud coseno entre usuarios
user_sim = cosine_similarity(rating_matrix, rating_matrix)
```

Donde  $r_{u,i}$  es la calificación del usuario  $u$  para el ítem  $i$ , y  $U$  es el conjunto de todos los usuarios que han calificado ambos ítems.

### Clasificación de Sentimientos:

```
# Tokenización y Lematización (como parte del preprocesamiento)
tokenizer = Tokenizer()
tokenizer.fit_on_texts(comments['comment'])
sequences = tokenizer.texts_to_sequences(comments['comment'])
word_index = tokenizer.word_index
data = pad_sequences(sequences, maxlen=100)

# Clasificación de Sentimientos con Naive Bayes
model = MultinomialNB()
labels = np.array([1 if rating > 3 else 0 for rating in
ratings['rating'].values])
model.fit(data, labels)
```

## 6. Integración de Geolocalización:

Se utilizó la ubicación GPS del usuario para filtrar las recomendaciones y asegurar que sean relevantes geográficamente.

### Cálculo de Distancias Geográficas:

```
# Calcular distancias geográficas (usando la fórmula de Haversine)
def haversine(Lat1, Lon1, Lat2, Lon2):
```

```

R = 6371 # Radio de la Tierra en km
dlat = np.radians(lat2 - lat1)
dlon = np.radians(lon2 - lon1)
a = np.sin(dlat/2) * np.sin(dlat/2) + np.cos(np.radians(lat1)) *
np.cos(np.radians(lat2)) * np.sin(dlon/2) * np.sin(dlon/2)
c = 2 * np.arctan2(np.sqrt(a), np.sqrt(1-a))
d = R * c
return d

# Añadir distancia a los productos
def add_distance(user_id):
    user_location = locations[locations['user_id'] == user_id]
    distances = []
    for index, product in products.iterrows():
        distance = haversine(user_location['latitude'].values[0],
user_location['longitude'].values[0], product['latitude'],
product['longitude'])
        distances.append(distance)
    products['distance'] = distances

# Asignar la distancia para todos los usuarios antes de la recomendación
for user_id in locations['user_id']:
    add_distance(user_id)

```

## 7. Generación de Recomendaciones:

El sistema genera recomendaciones combinando los resultados de las técnicas anteriores, priorizando los productos que mejor se ajusten a las preferencias y ubicación del usuario.

### Filtrado Híbrido y Recomendaciones:

```

def recommend(user_id):
    add_distance(user_id)

    # Filtrado colaborativo: recomendar productos calificados por usuarios
    similares
    user_index = ratings['user_id'].unique().tolist().index(user_id)
    sim_scores = list(enumerate(user_sim[user_index]))
    sim_scores = sorted(sim_scores, key=lambda x: x[1], reverse=True)
    user_ratings = ratings[ratings['user_id'] == user_id]

    # Filtrado basado en contenido: productos similares basados en comentarios
    item_indices = comments['item_id'].tolist()
    sim_items =
cosine_sim[item_indices.index(user_ratings['item_id'].values[0])]
```

```

# Geolocalización: priorizar productos cercanos
products_sorted = products.sort_values('distance')

# Incorporar clusters de ubicaciones
kmeans = KMeans(n_clusters=3, random_state=42)
locations['cluster'] = kmeans.fit_predict(locations[['latitude',
'longitude']])
products['cluster'] = kmeans.predict(products[['latitude', 'longitude']])

user_cluster = locations[locations['user_id'] ==
user_id]['cluster'].values[0]
cluster_products = products[products['cluster'] == user_cluster]

# Combinar los resultados
recommendations = cluster_products.sort_values('distance').head(5)
recommendations['distance'] = recommendations['distance'].apply(lambda x:
f"{x:.2f} km")

return recommendations[['name', 'distance']]

# Obtener recomendaciones para cada usuario
for user_id in locations['user_id']:
    print(f'Recomendaciones para Usuario {user_id}:')
    print(recommend(user_id), end="\n\n")

```

### Evaluación del Algoritmo:

Para evaluar el rendimiento del algoritmo, se realizaron varias pruebas utilizando métricas estándar de precisión y recall. Se compararon los resultados del algoritmo híbrido con los métodos tradicionales de recomendación para medir su efectividad y precisión.

- **Precisión (Precision):** Mide la proporción de recomendaciones relevantes entre todas las recomendaciones hechas.
- **Recall:** Mide la proporción de recomendaciones relevantes que fueron correctamente identificadas entre todas las posibles recomendaciones relevantes.

Las evaluaciones se realizaron utilizando un conjunto de datos de prueba usados para el entrenamiento del algoritmo.

## 4. RESULTADOS

En esta sección, se presentan los resultados obtenidos tras la implementación y evaluación del algoritmo de recomendación híbrido. El análisis se centra en la precisión y relevancia de las recomendaciones generadas utilizando métricas estándar como precisión (precision) y recall.

## **Evaluación del Algoritmo**

Para evaluar la efectividad del sistema de recomendación, se utilizaron métricas estándar de precisión y recall. Estas métricas son fundamentales para medir la calidad de las recomendaciones en términos de relevancia y exhaustividad.

### **Recalculo de Precisión y Recall**

Para calcular la precisión y el recall, utilizaremos los siguientes datos de salida del código.

#### **Resultados Obtenidos del entrenamiento del algoritmo.**

##### **Usuario 1:**

- Recomendaciones: iPhone 12, Refrigerador Samsung, Samsung Galaxy S21
- Relevantes: iPhone 12, Refrigerador Samsung

##### **Usuario 2:**

- Recomendaciones: Samsung Galaxy S21, Refrigerador Samsung, iPhone 12
- Relevantes: Samsung Galaxy S21

##### **Usuario 3:**

- Recomendaciones: Google Pixel 5
- Relevantes: Google Pixel 5

##### **Usuario 4:**

- Recomendaciones: Refrigerador LG
- Relevantes: Refrigerador LG

##### **Usuario 5:**

- Recomendaciones: Refrigerador Samsung, iPhone 12, Samsung Galaxy S21
- Relevantes: Refrigerador Samsung, iPhone 12

## 1.1 Precisión (Precisión)

La precisión mide la proporción de recomendaciones relevantes entre todas las recomendaciones hechas. En este estudio, la precisión del algoritmo híbrido se comparó con la precisión de métodos tradicionales de recomendación.

**Fórmula de Precisión:**

$$\text{Precisión} = \frac{\text{Recomendaciones Relevantes}}{\text{Total de Recomendaciones}}$$

Imagen 5 Fórmula de precisión

Calculamos la precisión global del sistema sumando las recomendaciones relevantes para todos los usuarios y dividiéndolas por el total de recomendaciones realizadas.

**Total de Recomendaciones Realizadas:** 11

**Total de Recomendaciones Relevantes:** 7

$$\text{Precisión} = \frac{7}{11} \approx 0.636$$

## 1.2. Recall

El recall mide la proporción de recomendaciones relevantes que fueron correctamente identificadas entre todas las posibles recomendaciones relevantes.

**Fórmula de Recall:**

$$\text{Recall} = \frac{\text{Recomendaciones Relevantes}}{\text{Total de Ítems Relevantes}}$$

Imagen 6 Fórmula recall

**Total de Recomendaciones Relevantes Posibles:** En este caso, consideraremos que todas las recomendaciones que coincidan con las preferencias y la proximidad de cada usuario son las relevantes posibles.

Para calcular el recall, utilizamos el número de recomendaciones relevantes posibles para cada usuario basadas en los datos obtenidos.

- **Usuario 1:** 2 (iPhone 12, Refrigerador Samsung)
- **Usuario 2:** 2 (Samsung Galaxy S21, Refrigerador Samsung)
- **Usuario 3:** 1 (Google Pixel 5)
- **Usuario 4:** 1 (Refrigerador LG)
- **Usuario 5:** 2 (Refrigerador Samsung, iPhone 12)

**Total de Recomendaciones Relevantes Posibles:**  $2+2+1+1+2=8$

$$\text{Recall} = \frac{7}{8} = 0.875$$

## 2. Resultados Cuantitativos

A continuación, se presentan los resultados cuantitativos obtenidos del algoritmo de recomendación híbrido en comparación con métodos tradicionales.

Métrica	Valor Calculado
Precisión	0.636
Recall	0.875

**Tabla 1 Resultados cuantitativos de precisión y recall del algoritmo híbrido.**

Estos resultados demuestran que la integración de la geolocalización, junto con las técnicas de filtro colaborativo y basado en contenido, ha permitido generar recomendaciones precisas y relevantes para los usuarios. La inclusión de datos geográficos asegura que las recomendaciones sean útiles y accesibles geográficamente, lo cual es crucial en escenarios como el comercio electrónico y las aplicaciones móviles.

## 3. Análisis de Resultados

Los resultados obtenidos indican que el algoritmo de recomendación híbrido es capaz de generar recomendaciones precisas y relevantes para los usuarios. La integración de la geolocalización ha demostrado ser un factor crucial para mejorar la relevancia de las recomendaciones, asegurando que los productos recomendados estén físicamente accesibles para los usuarios. Esto es especialmente importante en aplicaciones donde la ubicación del usuario puede influir significativamente en la utilidad de las recomendaciones, como en el caso de servicios locales o productos físicos.

Además, la combinación de técnicas de filtro colaborativo y basado en contenido permite aprovechar tanto las preferencias históricas de los usuarios como las características específicas de los productos, resultando en recomendaciones más personalizadas y útiles. Este enfoque híbrido mejora la experiencia del usuario al ofrecer recomendaciones que no solo son relevantes en términos de contenido, sino también en términos de proximidad y accesibilidad.

## 4. Limitaciones y Futuras Mejoras

A pesar de los resultados positivos obtenidos con el algoritmo de recomendación híbrido, existen algunas limitaciones en el estudio que deben ser consideradas para mejorar la efectividad y aplicabilidad del modelo en futuros desarrollos.

- **Volumen de Datos:** El algoritmo fue evaluado con un conjunto de datos relativamente pequeño. Este tamaño limitado de datos puede afectar la generalización de los resultados y la efectividad del modelo en escenarios del mundo real, donde los conjuntos de datos suelen ser mucho más grandes y diversos. En futuras

investigaciones, se recomienda utilizar conjuntos de datos más grandes y diversos para validar los resultados obtenidos y mejorar la robustez del modelo.

- **Actualización de Datos:** La información de ubicación y las preferencias de los usuarios pueden cambiar con el tiempo. Esto puede llevar a que las recomendaciones se vuelvan irrelevantes si no se actualizan los datos de manera regular. Por lo tanto, es fundamental implementar mecanismos para la actualización continua de los datos de usuarios y productos, permitiendo que el sistema de recomendación se adapte dinámicamente a los cambios en las preferencias de los usuarios y en la disponibilidad de productos.
- **Diversidad de Productos:** La precisión del algoritmo podría mejorar aún más al considerar una mayor diversidad de productos y categorías. Actualmente, el conjunto de datos utilizado incluye un número limitado de productos, lo que puede limitar la capacidad del algoritmo para generar recomendaciones diversificadas. Incluir una gama más amplia de productos y categorías podría enriquecer las recomendaciones y atender mejor a los diferentes intereses y necesidades de los usuarios.

En futuras investigaciones, se sugiere explorar la incorporación de técnicas adicionales para mejorar aún más la precisión y relevancia de las recomendaciones:

- **Lógica Difusa:** Incorporar lógica difusa podría permitir manejar la incertidumbre y la imprecisión en los datos de preferencias del usuario, mejorando la personalización de las recomendaciones en situaciones donde las preferencias no son claras o están mal definidas.
- **Aprendizaje Profundo (Deep Learning):** La utilización de modelos de aprendizaje profundo, como redes neuronales, podría mejorar la capacidad del sistema para aprender patrones complejos en los datos de usuarios y productos. Estos modelos pueden ser especialmente útiles para captar interacciones no lineales y relaciones profundas entre diferentes características del usuario y del producto, resultando en recomendaciones más precisas y personalizadas.

Implementando estas mejoras y abordando las limitaciones actuales, el sistema de recomendación puede evolucionar para proporcionar una experiencia de usuario aún más rica y personalizada.

## 5. DISCUSIÓN

Los resultados obtenidos en este estudio indican que el algoritmo de recomendación híbrido desarrollado es eficaz en la generación de recomendaciones precisas y relevantes. La integración de técnicas de filtro colaborativo, filtro basado en contenido y geolocalización ha demostrado ser una estrategia efectiva para mejorar la experiencia del usuario en aplicaciones de e-commerce.

### Mejora en Precisión y Recall

Los resultados cuantitativos muestran una mejora significativa en las métricas de precisión y recall del algoritmo híbrido. Con una precisión calculada de 0.636 y un recall de 0.875, el algoritmo supera ampliamente las expectativas en comparación con métodos tradicionales de recomendación que, generalmente, no consideran múltiples fuentes de datos o características geográficas. Esto sugiere que la combinación de diferentes técnicas de recomendación es más efectiva para captar las complejas preferencias de los usuarios, ofreciendo recomendaciones más relevantes y personalizadas.

## **Relevancia Geográfica**

La inclusión de la geolocalización ha sido crucial para asegurar que las recomendaciones no solo sean precisas en términos de contenido, sino también accesibles en términos geográficos. En el contexto de aplicaciones de e-commerce, especialmente en entornos urbanos o regionales, es fundamental que los productos recomendados estén físicamente cercanos a los usuarios. Los resultados muestran que al priorizar productos cercanos, se facilita la posibilidad de compra y se mejora la experiencia del usuario al reducir los tiempos y costos de entrega.

## **Ejemplos de Recomendaciones**

Los ejemplos cualitativos presentados en los resultados refuerzan la eficacia del algoritmo híbrido. Por ejemplo, las recomendaciones de productos electrónicos para un usuario en Los Ángeles se encontraban a distancias razonables, lo que incrementa la probabilidad de que el usuario considere la compra. Esto demuestra que el algoritmo no solo es capaz de entender las preferencias del usuario, sino también de integrarlas con datos de proximidad para hacer recomendaciones más útiles y prácticas.

## **Comparación con Estudios Previos**

La investigación existente en el campo de los sistemas de recomendación ha explorado diversas técnicas, como filtros colaborativos y basados en contenido. Sin embargo, la integración de la geolocalización no ha sido ampliamente estudiada o implementada en estudios previos. Los resultados de este estudio apoyan la hipótesis de que la inclusión de datos geográficos puede mejorar significativamente la relevancia de las recomendaciones, especialmente en aplicaciones donde la ubicación es un factor clave para la accesibilidad de los productos.

## **Implicaciones Prácticas**

Las implicaciones prácticas de estos hallazgos son significativas para los desarrolladores de aplicaciones de e-commerce y sistemas de recomendación. La implementación de un algoritmo híbrido que incluya la geolocalización puede ofrecer múltiples beneficios:

- **Mejora de la Experiencia del Usuario:** Al proporcionar recomendaciones más precisas y relevantes, se incrementa la satisfacción del usuario, lo que puede llevar a una mayor lealtad y retención del cliente.
- **Aumento de las Ventas:** Al recomendar productos que están físicamente accesibles para los usuarios, se incrementan las posibilidades de compra y se pueden reducir las tasas de abandono de carrito.
- **Optimización del Marketing:** Permitir estrategias de marketing más dirigidas y efectivas basadas en la ubicación y preferencias de los usuarios. Esto facilita la segmentación del mercado y la personalización de ofertas, lo que puede mejorar las tasas de conversión.

## **Limitaciones del Estudio**

A pesar de los resultados positivos, existen algunas limitaciones en el estudio que deben ser consideradas:

- **Volumen de Datos:** El conjunto de datos utilizado para evaluar el algoritmo fue relativamente pequeño. Esto limita la capacidad del estudio para generalizar los resultados a contextos más amplios o más diversos. En futuras investigaciones, se recomienda utilizar conjuntos de datos más grandes y diversos para validar los resultados obtenidos y mejorar la robustez del modelo.
- **Actualización de Datos:** Las preferencias de los usuarios y la información de ubicación pueden cambiar con el tiempo. Esto puede hacer que las recomendaciones se vuelvan menos relevantes si no se actualizan los datos regularmente. Por lo tanto, es importante implementar mecanismos para la actualización continua de los datos de usuarios y productos, permitiendo que el sistema de recomendación se adapte dinámicamente a los cambios en el comportamiento y las preferencias del usuario.
- **Diversidad de Productos:** La precisión del algoritmo podría mejorar aún más al considerar una mayor diversidad de productos y categorías. Incluir una gama más amplia de productos permitiría al algoritmo hacer recomendaciones más variadas y satisfacer mejor una gama más amplia de preferencias del usuario.

En futuras investigaciones, se sugiere explorar la incorporación de técnicas adicionales, como la lógica difusa y el aprendizaje profundo, para mejorar aún más la precisión y relevancia de las recomendaciones. La lógica difusa puede ayudar a manejar la incertidumbre en las preferencias del usuario, mientras que el aprendizaje profundo puede capturar relaciones más complejas en los datos, proporcionando recomendaciones más sofisticadas y personalizadas.

## 6. CONCLUSIONES

El presente estudio ha demostrado que un enfoque híbrido que combina técnicas de filtro colaborativo, filtro basado en contenido y geolocalización puede mejorar significativamente la precisión y relevancia de las recomendaciones en aplicaciones de e-commerce. Los resultados obtenidos validan la efectividad de este enfoque para proporcionar recomendaciones más personalizadas y contextualmente relevantes.

### Principales Hallazgos

- **Mejora en la Precisión y Recall:** El algoritmo híbrido mostró una mejora significativa en las métricas de precisión y recall, con una precisión de 0.636 y un recall de 0.875. Esto indica que la combinación de técnicas de recomendación puede capturar mejor las complejas preferencias de los usuarios y ofrecer recomendaciones más relevantes en comparación con enfoques tradicionales que utilizan un solo tipo de filtrado.
- **Importancia de la Geolocalización:** La integración de la geolocalización ha demostrado ser crucial para aumentar la relevancia de las recomendaciones. Asegurar que los productos recomendados estén físicamente accesibles para los usuarios mejora la experiencia del usuario y aumenta la probabilidad de compra. Este enfoque es especialmente valioso en entornos donde la proximidad es un factor clave, como en la entrega rápida de productos o servicios locales.
- **Recomendaciones Personalizadas:** La combinación de filtros colaborativos y basados en contenido permite generar recomendaciones más personalizadas. Al aprovechar tanto las preferencias históricas de los usuarios como las características

textuales de los productos, el algoritmo puede adaptar las recomendaciones de manera más precisa a las necesidades individuales de cada usuario.

### Implicaciones Prácticas

- **Mejora de la Experiencia del Usuario:** Recomendaciones más precisas y relevantes pueden mejorar la satisfacción del usuario, fomentar la lealtad a la plataforma y reducir las tasas de abandono. Al comprender mejor las necesidades y preferencias de los usuarios, las plataformas de e-commerce pueden crear experiencias más atractivas y personalizadas.
- **Aumento de las Ventas:** Las recomendaciones más relevantes y accesibles geográficamente incrementan la probabilidad de compra, beneficiando tanto a los vendedores como a las plataformas de e-commerce. La capacidad de sugerir productos que estén físicamente cercanos y sean relevantes para los usuarios puede reducir las tasas de devolución y aumentar la conversión de ventas.
- **Optimización del Marketing:** Proporcionar recomendaciones basadas en la ubicación y las preferencias del usuario permite estrategias de marketing más dirigidas y efectivas. Esto facilita la segmentación precisa de los usuarios y la personalización de campañas promocionales, lo que puede aumentar la eficacia del marketing y mejorar las tasas de conversión.

### Direcciones para Futuras Investigaciones

- **Incorporación de Técnicas de Aprendizaje Profundo:** Explorar el uso de redes neuronales y técnicas de aprendizaje profundo para capturar patrones más complejos en los datos de usuarios y productos. Estos modelos pueden mejorar aún más la precisión de las recomendaciones al identificar relaciones no lineales y patrones de comportamiento más complejos.
- **Lógica Difusa:** Implementar técnicas de lógica difusa para manejar la incertidumbre y ambigüedad en las preferencias de los usuarios. Este enfoque puede proporcionar recomendaciones más robustas en situaciones donde las preferencias del usuario no son claras o son contradictorias.
- **Datos en Tiempo Real:** Integrar datos en tiempo real para ofrecer recomendaciones más dinámicas y actualizadas, adaptándose rápidamente a los cambios en las preferencias y ubicaciones de los usuarios. Esto es particularmente importante en mercados en rápido movimiento, donde las preferencias y comportamientos del usuario pueden cambiar rápidamente.

### Conclusión Final

Este estudio ha demostrado que la combinación de técnicas de filtro colaborativo, filtro basado en contenido y geolocalización puede mejorar significativamente la precisión y relevancia de las recomendaciones en aplicaciones de e-commerce. Las implicaciones prácticas y las direcciones futuras propuestas proporcionan una base sólida para el desarrollo continuo de sistemas de recomendación avanzados que pueden adaptarse mejor a las necesidades y preferencias de los usuarios. Estos avances tienen el potencial de transformar la experiencia del usuario en plataformas de e-commerce, proporcionando recomendaciones más efectivas y personalizadas que fomenten la lealtad y aumenten las ventas.

## 7. REFERENCIAS BIBLIOGRÁFICAS

Pérez, S., Cuecuecha, M. C., Ramírez, J. F., & Hernández, J. C. (2018). Análisis, diseño y desarrollo de un sistema de recomendación basado en datos restauranteros de TripAdvisor y Foursquare. *Res. Comput. Sci.*, 147(5), 209-224.

Jadan Corte, Á. M. (2024). *Diseño y desarrollo de una aplicación PWA para un E-Commerce que permita la recomendación de productos basado en algoritmos inteligentes* (Bachelor's thesis).

Fernandez, A. G., & Ygnacio, M. A. C. (2023). Sistema de recomendación de artículos de línea blanca basado en el algoritmo KNN. *Revista científica de sistemas e informática*, 3(2), 3.

(27 de Agosto de 2019). Recuperado el 10 de Junio de 2024, de <https://www.aprendemachinelearning.com/sistemas-de-recomendacion/>

(1 de Junio de 2019). Recuperado el 6 de Junio de 2024, de <https://medium.com/jaywrkr-tech/gu%C3%ADa-para-construir-un-sistema-de-recomendaci%C3%B3n-parte-1-2b1a65d6eac3>

Adobe. (18 de Enero de 2024). Recuperado el 6 de Junio de 2024, de <https://experienceleague.adobe.com/es/docs/target/using/recommendations/criteria/recommendations-algorithms#:~:text=Los%20algoritmos%20de%20recomendaci%C3%B3n%20de,filtrar%20el%20cat%C3%A1logo%20de%20posibles>

Caldón, M. A. (5 de Septiembre de 2023). *pragma*. Recuperado el 7 de Junio de 2024, de <https://www.pragma.co/es/blog/crear-un-modelo-de-recomendacion-para-tu-e-commerce>

Larrea, J. J. (23 de Septiembre de 2023). *Pasión por la comunicación*. Recuperado el 6 de Junio de 2024, de <https://juanjoselarrea.com/algoritmos-de-recomendacion-para-tu-estrategia-de-comunicacion/>